

# Métodos de Visualización de Datos Georeferenciados: Marco Teórico

**Diego Correa Tristain**

email: [algoritmia@labormedia.cl](mailto:algoritmia@labormedia.cl)

encomendado por :

Guillermo Acuña Arquitectos Asociados

conceptos claves: sala de control, sala de situación, realidad virtual, strata

---

**Resumen**-- Analizar la ciudad como una red de múltiples sucesos propone diversas problemáticas de representación, tanto numérica como simbólica matemáticas. Este escrito propone dos métodos que permiten analizar las relaciones tanto de una misma capa de información, distinguida por su método de medición, geoposición y temporalidad, así también como entre capas. De esta manera, se busca enfrentar la complejidad urbana como la red de un espacio topológico de causalidades que permitan construir la base explicativa de los sucesos, intensidades y probabilidades de una ciudad.

---

## I. Introducción

En respuesta al ordenamiento matemático de información georeferenciada podemos considerar modelos causales de estados o eventos en redes de situaciones en los cuales no sólo tendremos distintos niveles de información, sino también diversas estructuras causales/explicativas de las mismas. Mediciones de acontecimientos pueden ser ordenados en capas y articulaciones entre ellas de tal forma que la bondad del modelo representará de la mejor manera posible la dinámica de los acontecimientos observados. Para ello, es necesario tener criterios de medición de bondad de los modelos con los cuales se construye la dialógica de aprendizaje con el cual interpretamos las capas de información.

Para nuestro propósito estudiaremos la aplicación de dos modelos, estos son el modelo de cluster de markov (MCL) y el caso especial de redes bayesianas (BN), también llamadas redes de creencias. Ambos pertenecen a la familia de modelos en grafos probabilísticos, provenientes de teoría de la probabilidad y ampliamente usados en disciplinas diversas, como

física estadística y visión computacional.

## II. Capas de Información y Causalidad.

Para el diseño de un modelo explicativo de redes de situaciones en base a observaciones medibles usaremos un método propio del estudio de espacios topológicos. Los modelos en grafos, representados como espacios matriciales representan redes de sucesos causales distinguibles en tipo de observación, tiempo y ubicación. Estas distinciones nos permiten construir las estructuras que articulan estas capas. Tendremos diversos tipos de observación según método, diversos momentos del tiempo y diversas coordenadas de ubicación. La métrica relacionada entre ellas es la reconstrucción de la realidad subyacente a las mediciones.

A modo de clarificación, si un evento conduce con cierta probabilidad a otro, diremos que su relación es condicional, de otra forma diremos que su relación es incondicional o marginal. Por otro lado, si la condicionalidad es consecutiva entre dos nodos diremos que es dependiente, de otra manera, si existe una secuencia de condicionalidad no consecutiva, diremos que son sucesos independientes.

## III. Manto de Markov.

Es deseable en modelos en grafos probabilísticos reducir el nivel de complejidad del cálculo conjunto de probabilidades, en los cuales se comparan capas de información para extraer relaciones causales / explicativas entre ellas. Las métricas entre intensidades que pertenecen a una misma capa de información se pueden relacionar de forma básica bajo la hipótesis de cercanía o relación espacial, que si bien no constituye una relación causal directa entre eventos o sucesos, si pertenecen a la estratificación propia del espacio al cual pertenecen. Esta hipótesis nos permite inferir que diversas capas se relacionan en base a su métrica espacial / georeferencial basada en coordenadas sobre el globo.

Las redes bayesianas son un método conveniente en la reducción de dicha complejidad probabilística. La forma de relacionar la probabilidad de dos sucesos conjuntos, según el teorema de bayes, es la siguiente:

$$P(W|L) = \frac{P(L|W)P(W)}{P(L)} = \frac{P(L|W)P(W)}{P(L|W)P(W) + P(L|M)P(M)} \quad (1)$$

, donde  $P(W|L)$  corresponde a la probabilidad de ocurrencia del suceso  $W$  dado el suceso  $L$ .


Aplicado a una red de sucesos tenemos:

$$P(A_i|A) = \frac{P(A_i)P(A|A_i)}{\sum_{j=1}^N P(A_j)P(A|A_j)} \quad (2)$$

, donde  $\sum_{j=1}^N P(A_j)P(A|A_j)$  es la probabilidad conjunta  $A_j \cap A$

En base a este esquema de probabilidad, identificaremos un tipo de independencia relacional llamada “manto de markov”. Por cada nodo, las relaciones del manto en base a ese nodo serán todas las situaciones o nodos que lo explican, tanto como las situaciones que él mismo explica como las situaciones que explican a los hijos o nodos explicados por él. De esta manera, tendremos nodos relacionados bajo ese manto y otros nodos independientes entre si basado en este criterio.

Como ejemplo, tenemos el diagrama donde, por ejemplo, A es independiente a K en base al manto de markov, pero dependiente o relacionado a Z. Así mismo, X, Y, B y Z pertenecen al manto de markov de A.

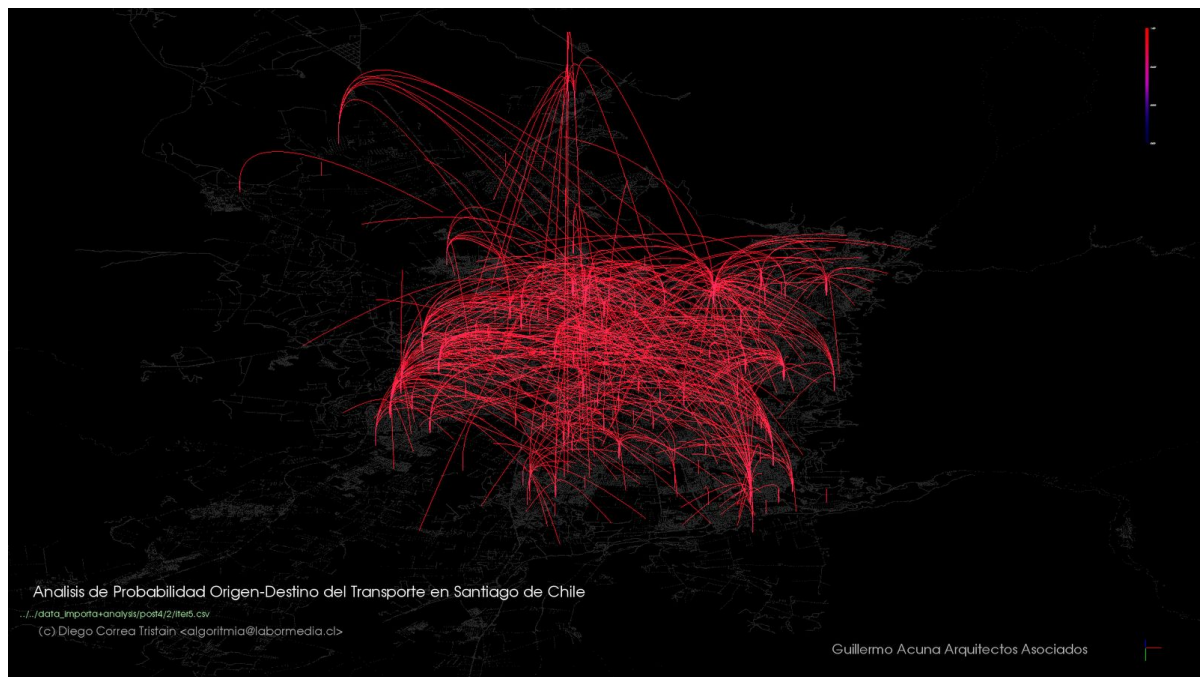


## IV. Clustering

Para efectos de análisis, reconoceremos nodos de red que tengan mayor grado de interconexión basados en un modelo llamado modelo de Markov junto con un método llamado clustering de Markov.

Este modelo reconoce estados de una red como forma de describir sucesos que ocurren en ella. Las probabilidades asociadas a estos sucesos determinan el estado siguiente, de manera que las relaciones históricas sólo dependen del estado anterior. De esta manera, obtenemos un grafo de relaciones entre los nodos que contienen pesos en sus conexiones, que determinarán el siguiente estado.

El método de clustering de Markov se basa en la forma en que estas probabilidades cambian para cada nodo si existe iteración de esta red de probabilidades en el tiempo. Si existe, entonces es posible demostrar que converge. Esta convergencia entonces unirá las partes de la red más interconectadas y desestimará las particiones de la red que están más debilmente interconectadas entre si. Al final obtendremos un grafo donde aparecerán estrellas alrededor de nodos de la red. Estas estrellas constituirán particiones de la red que tendrán un grado de interconexión medida en base a las probabilidades de la tabla y distinguible a otras particiones de la red.



Ejemplo de clustering de Markov. Se puede ver claramente como, después del análisis, ciertos puntos conectan en forma de estrella a otros, concentrando de esta manera un cluster de sucesos en base a las probabilidades de la tabla.